



深圳技术大学
SHENZHEN TECHNOLOGY UNIVERSITY

本科毕业论文（设计）

题目：图神经网络算法在多个抗体
结合位点数据集上的分析与评估

姓 名	马 依 涵
学 院	大 数 据 与 互 联 网 学 院
专 业	数 据 科 学 与 大 数 据 技 术
学 号	202100203042
指 导 教 师	王 鑫
职 称	助 理 教 授
提 交 日 期	2025 年 5 月 5 日

深圳技术大学本科毕业论文（设计）诚信声明

本人郑重声明：所呈交的毕业论文（设计），题目《图神经网络算法在多个抗体结合位点数据集上的分析与评估》是本人在指导教师的指导下，独立进行研究工作所取得的成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式注明。除此之外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。本人完全意识到本声明的法律结果。

毕业论文（设计）作者签名：

日期： 年 月 日

目录

【摘要】	I
【Abstract】	II
1. 绪论	1
1.1 选题背景与意义	1
1.2 国内外发展现状	2
1.3 论文研究目标以及主要研究工作	4
2. 图神经网络模型的理论基础与环境构建	6
2.1 图神经网络（Graph Neural Networks, GNN）	6
2.2 硬件配置	8
2.3 软件配置	8
2.4 PyTorch 深度学习框架	8
2.5 PyMol 分子可视化软件	8
2.6 AntiBERTy 抗体预训练模型库	9
3. NanoKGAT 模型	10
3.1 模型概述与架构	10
3.2 与其他模型的异同点	13
4. 模型训练与评估	17
4.1 纳米抗体数据来源与格式	17
4.2 基于纳米抗体结构的特征向量数据集构建	17
4.3 模型权重文件的训练与保存	21
4.4 模型评估方法	21

4.5 实验结果分析	23
5. 模型对比与未来展望	28
5.1 研究总结与模型对比	28
5.2 未来展望	29
参考文献	30
致谢	32

图神经网络算法在多个抗体结合位点数据集上的分析与评估

【摘要】 纳米抗体源自骆驼科动物免疫系统，通过人工加工和分离抗原结合蛋白获得。它们的小分子尺寸和高特异性赋予了纳米抗体在各个领域的广泛潜在应用。然而，通过实验确定纳米抗体结合位点既昂贵又耗时，而传统的计算方法往往缺乏足够的准确性。为了提高预测准确性，我们提出了 NanoKGAT 纳米抗体结合位点预测模型，它采用图神经网络（Graph Neural Networks, GNN）和抗体预训练语言模型 AntiBERTy，充分利用纳米抗体的序列和三维结构信息。具体而言，我们的方法首先利用 AntiBERTy 从纳米抗体序列中提取高层次的序列特征，这些特征捕捉了氨基酸残基之间的复杂依赖关系。同时，我们从纳米抗体的三维结构中提取空间特征，构建纳米抗体图结构，并采用 EdgeConv 和 GATConv 两种图卷积机制进行特征学习。EdgeConv 增强了节点之间的边信息，而 GATConv 通过注意力机制动态调整不同残基的权重，进一步提升了模型的预测精度。在模型架构上，我们结合了一维卷积神经网络来处理序列特征，并将其与图卷积层的输出进行融合，以形成综合的特征表示。最终，通过全连接层和 sigmoid 激活函数，模型将会输出每个氨基酸残基的是否属于结合位点的概率。我们的方法仅依赖于纳米抗体自身的序列和结构信息，无需额外的抗原数据，显著简化了预测流程。

【关键词】 纳米抗体 抗体预训练模型；结合位点预测 深度学习 图神经网络

Analysis and evaluation of GNN algorithms on multiple antibody binding site datasets

【Abstract】 Nanobodies are artificial antibodies derived from the immune systems of camelid animals, obtained through artificial processing and isolation of antigen-binding proteins. Their small molecular size and high specificity endow nanobodies with broad potential applications across various fields. However, determining the paratope (antigen-binding region) of nanobodies through experimental methods is both expensive and time-consuming, and traditional computational methods often lack sufficient accuracy. To improve prediction accuracy, we propose NanoKGAT, a method that employs Graph Neural Networks (GNN) and the antibody pre-trained language model AntiBERTy to fully leverage the sequence and three-dimensional structural information of nanobodies. Specifically, our method first utilizes AntiBERTy to extract high-level sequence features from the nanobody sequences. These features capture the complex dependencies between amino acid residues. Simultaneously, we extract spatial features from the three-dimensional structure of the nanobody, construct a graph structure, and employ two graph convolution mechanisms: EdgeConv and GATConv for feature learning. EdgeConv enhances the edge information between nodes, while GATConv dynamically adjusts the weights of different residues through an attention mechanism, thereby further improving the prediction accuracy of the model. In terms of model architecture, we incorporate a one-dimensional convolutional neural network to process the sequence features and fuse them with the output of the graph convolution layers to form a comprehensive feature representation. Finally, through a fully connected layer and a sigmoid activation function, the model outputs the probability of each amino acid residue belonging to the paratope. Our approach relies solely on the sequence and structural information of the nanobody itself, without the need for additional antigen data, significantly simplifying the prediction process.

【Key words】 Nanobodies; Pre-trained Models; Binding Site Prediction; Deep Learning; Graph Neural Networks (GNN)

1. 绪论

1.1 选题背景与意义

抗原和抗体是生物学上的经典概念。抗原通常是指能够引起机体产生免疫反应的物质，比如病毒、细菌或者其他异物。而抗体，则是我们身体为了抵抗这些外来物质，由免疫系统产生的一种特殊蛋白质。简而言之，抗原好比是“坏蛋”，而抗体就是身体制造出来的“警察”。纳米是长度单位，用肉眼是完全看不出来的。对比其他尺寸的抗体，这种“纳米”级别的抗体，如图 1-1 所示，红色部分为抗体区域。纳米抗体由于仅保留传统抗体的重链可变区（VHH），其分子量仅为 15 kDa 左右，体积较常规抗体缩小约 90%。能够发挥其特有的细胞屏障穿透能力，精准靶向特定的细胞和分子。纳米抗体的发现，对于生物医学领域来说，是具有突破意义的。




图 1-1 抗体结构对比

通过对比其他抗体，可以更加精确了解纳米抗体的特征特点，如高稳定性和高特异性等。对比结果如表 1-1 所示。由此可见，纳米抗体在关键性能参数上展现显著优势：其分子量仅为传统抗体的 1/10，体积较 Y 型抗体缩小约 80%，这种尺寸优势与其独特的单域单链结构直接相关。在稳定性方面，纳米抗体表现出超越常规抗体片段的强耐受性，显著优于传统抗体。通过可视化工具分析纳米抗体的结构，发挥纳米抗体的化学性质，开发与纳米抗体相关的医疗药物或医学诊断手段，实现精确的药物递送，为个性化医疗开辟新的道路。

表 1-1 纳米抗体与其他蛋白质分子的对比总结

特性	传统抗体	scFv	Fab 片段	纳米抗体	单域抗体	融合蛋白	多肽
分子量 (kDa)	~150	~25-30	~50	~12-15	~12-15	取决于融合部分	~1-10
大小 (nm)	~14-15	~4-5	~5-7	~2-3	~2-3	取决于融合部分	~1-3
结构	Y 形, 四链	单链	两链	单域, 单链	单域	融合结构	短链
稳定性	中等	中等	中等	高	高	取决于融合部分	低
特异性	高	高	高	高	高	高	中等
生产难度	高	中等	中等	低	低	中等	低
应用	广泛	广泛	广泛	广泛	广泛	特定应用	特定应用

目前, 国内外已建立了多个权威的抗体数据库, 如 RCSB、INDI、SAbDab、PDB-E、sdAb-DB 以及 NCBI Virus 等, 这些数据库为研究人员提供了丰富的数据支持, 可以通过登录这些数据库的官网查询抗体的相关性信息, 如抗体来源生物种类, 分子质量, 与其他分子对接的信息等。

对纳米抗体这样独特的结构, 运用以往矩阵式的结构数据并不能很好的分析纳米抗体, 应用纳米抗体。但同时分子与分子之间的相互关系使得将蛋白质分子的结构视为图结构数据得以可能。而图神经网络是目前较为前沿和强大的深度学习框架, 在处理图结构数据上有得天独厚的优势, 它会通过节点和边的信息来捕捉蛋白质分子的整体结构和局部特征。因此, 在纳米抗体数据集上, 应用图神经网络算法是顺其自然的。但是由于目前图神经网络算法种类繁多, 在不同的数据集上的表现差异化很大, 这导致目前应用于纳米抗体数据集研究上的图神经网络较为缺失。

为了填补这一空白, 我们将从上述多个权威数据库中收集整理蛋白质分子数据, 提取纳米抗体的结构特征, 构建纳米抗体矢量图结构数据, 形成图神经网络数据集。随后, 在这些数据集上应用图神经网络算法, 评估算法在数据上的表现。这一研究旨在为研究者提供有价值的参考, 推动纳米抗体在药物研发领域的发展。

1.2 国内外发展现状

2020 年, 抗体的高度特异性和低免疫原性使其在治疗市场中占据了主导地

位。目前，通过实验方法确定抗体与抗原的结合方式以及潜在的中和效应既耗时又昂贵。2014 至 2021 期间，为了提供一种更经济、更快速的替代方案，研究人员开发了计算对接工具，用于预测结合效果。然而，现有的计算工具往往无法准确重现抗体-抗原结合过程，并且通常无法真正实现高通量应用。

但预测抗体的结合位点不仅可以更好地估计其结合构象，还可以指示关键的残基位点，以便通过突变来改变结合特性。于是，2018 年研究人员提出一种广泛使用且免费提供的基于序列的旁位预测工具 Parapred^[2]，它利用卷积神经网络和循环神经网络进行预测。近期的一些旁位预测尝试，例如 PECAN 则引入了结构信息，将抗体结构表示为图结构。PECAN 需要同时输入抗体和抗原的结构信息，并使用图卷积注意力网络进行处理，但基于这些输入，其性能优于 Parapred。

而深度学习方法如 CNN 和 GNN，目前已在传统抗体领域得到一定的应用。通过对比 Parapred、PECAN 和深度学习方法的特性，正如表 1-2 所示，使用深度学习预测纳米抗体旁位具有可行性。

表 1-2 Parapred、PECAN、深度学习性能对照表

特性	Parapred	PECAN	深度学习
数据需求	仅需抗体序列信息	需要抗体和抗原的序列和结构信息	需要大量标注数据，类型多样（序列、结构等）
计算效率	高（仅处理序列数据）	中等（处理图结构数据）	中等至低（取决于模型架构和数据规模）
预测精度	有限（缺乏结构信息）	高（结合结构信息）	高（强大的特征学习能力）
模型复杂度	中等（CNN + RNN）	高（图卷积注意力网络）	高（取决于具体架构，如 GNN、Transformer 等）
适用场景	快速、大规模序列预测	高精度、结构依赖性强的预测	多样化应用场景，复杂任务
可解释性	中等（CNN 和 RNN 的部分可解释性）	较低（图结构模型通常较难解释）	较低（深度学习模型通常为“黑箱”）
拓展性	有限（主要依赖序列信息）	中等（可扩展到更多结构信息）	高（易于扩展到多模态数据和不同任务）
应用场景	基于序列的旁位预测工具	结合结构信息的旁位预测工具	例如 AlphaFold2（蛋白质结构预测）
技术实现	使用 CNN 和 RNN 进行序列处理	使用图卷积注意力网络处理图结构数据	多种架构，如 GNN、Transformer、CNN 等

数据预处理	主要是序列数据的预处理	需要对序列和结构数据进行图结构构建	复杂的数据预处理，包括特征工程、数据增强等
训练时间	较短（序列数据处理速度快）	中等（处理图结构数据需要更多时间）	较长（深度模型训练通常耗时）
硬件需求	低（普通 CPU 即可）	中等（需要 GPU、支持）	高（需要 GPU 甚至 TPU 支持）
主要优势	计算速度快，易于获取和使用	结合结构信息，预测精度高	强大的特征学习能力，灵活的应用能力
主要不足	缺乏结构信息，精度有限	数据和计算资源需求高，模型复杂度高	需要大量数据和计算资源，模型调试复杂

1.3 论文研究目标以及主要研究工作

本研究聚焦于应用图神经网络预测纳米抗体的旁位预测。旁位，也叫做表位，可以理解为是分子细胞表面上的特定区域，通常是表面上的 5~8 个氨基酸的残基，这些区域活性更强，抗体表位能够被其他抗原识别，与抗原的特定区域发生紧密结合，促发对外来病原体或异常细胞的免疫反应。

抗体表位预测的主要训练任务是一个二分类问题，即将蛋白质序列中的每个残基标记为可能的表位残基或非表位残基。针对这个问题，具体研究目标包含以下几点：构建适用于纳米抗体的预训练数据集，并利用深度学习技术从纳米抗体的序列和结构信息中提取有价值的特征；开发基于图神经网络的深度学习模型，实现对纳米抗体旁位区域的精准预测，为纳米抗体-抗原相互作用研究提供新的思路和方法；深入分析模型学习到的特征和机制，验证其对纳米抗体空间结构的理解能力，并评估其在实际应用中的潜力；推动深度学习技术在纳米抗体领域的应用，为未来开发更高效的纳米抗体药物和诊断工具奠定基础。

具体研究内容涵盖以下几个方面：

1. 纳米抗体数据集的构建与整合

从 RCSB、INDI、SAbDab、PDB-E、sdAb-DB、NCBI Virus 等权威数据库中，系统性地收集纳米抗体的结构信息、序列数据及相关实验数据。对收集到的数据进行清洗、去重、标准化处理，确保数据质量，为后续分析奠定基础。根据研究需求，构建多个具有不同侧重点的纳米抗体数据集，包括但不限于结构数据集、

序列数据集及功能数据集。

2. 图结构表示与特征提取

将纳米抗体的三维结构转化为图结构数据，节点代表氨基酸残基，边反映氨基酸间的相互作用或空间接近性。为每个节点和边设计合理的特征向量，包括但不限于氨基酸类型、物理化学性质、空间位置信息等，以全面反映纳米抗体的结构特性。利用特征选择或降维技术，优化特征集，提高后续 GNN 模型的训练效率和预测性能。

3. 图神经网络算法的应用与评估

选取 GNN 算法，在构建的纳米抗体数据集上训练 GNN 模型，调整模型参数，优化模型结构，以提高对纳米抗体结构和功能的预测能力，评估 GNN 模型在纳米抗体旁位预测任务上的性能。

4. 实验验证与结果分析

针对 GNN 算法预测的新纳米抗体或优化后的药物递送系统，设计实验方案进行验证。实施相关实验，收集实验数据。对实验数据进行统计分析，评估 GNN 算法预测的准确性和实用性，为进一步的临床应用提供科学依据。

2. 图神经网络模型的理论基础与环境构建

2.1 图神经网络（Graph Neural Networks, GNN）

纳米抗体可以自然地表示为图结构，图神经网络则是一种可以专门用于处理图结构数据的深度学习模型。其中，纳米抗体的氨基酸残基作为节点，残基之间的化学键或空间关系作为边。

将每个氨基酸残基表示为一个节点，包含以下特征：

1. 类别特征：氨基酸类型（20 种标准氨基酸）。
2. 物理化学特征：如疏水性、电荷、极性等。
3. 位置特征：残基在序列中的位置。

形式化地，节点特征可以表示为：

$$x_v = [c_v, p_v, l_v]. \quad (2-1)$$

其中：

1. c_v 是氨基酸的类别嵌入向量。
2. p_v 是物理化学特征向量。
3. l_v 是位置特征向量。

边可以表示残基之间的空间关系或化学键。例如，可以使用 K 近邻（KNN）方法根据残基的空间距离构建边，或者使用共价键和氢键等化学键关系。

边特征可以表示为：

$$\mathbf{e}_{uv} = [d_{uv}, t_{uv}]. \quad (2-2)$$

其中：

1. d_{uv} 是残基 u 和 v 之间的距离。
2. t_{uv} 是边类型（如共价键、氢键等）。

图卷积网络通过聚合邻居节点的信息来更新每个节点的表示。典型的 GCN 层可以表示为：

$$\mathbf{h}_v^{(l+1)} = \sigma \left(\mathbf{W}^{(l)} \sum_{u \in \mathcal{N}(v) \cup \{v\}} \frac{1}{\sqrt{\deg(u)\deg(v)}} \mathbf{h}_u^{(l)} \right). \quad (2-3)$$

其中：

1. $\mathbf{h}_u^{(l)}$ 是节点 v 在第 1 层的隐藏表示。
2. $\mathcal{N}(v)$ 是节点 v 的邻居集合。
3. $\mathbf{W}^{(l)}$ 是可训练的权重矩阵。
4. σ 是激活函数（如 ReLU）。
5. $\deg(v)$ 是节点 v 的度数。

我们通过引入注意力机制 Graph Attention Networks (GAT) 增强模型对重要邻居节点的关注。GAT 的核心是通过注意力权重动态衡量节点间的重要性，使用注意力权重来聚合邻居信息：

$$\mathbf{h}_v^{(l+1)} = \sigma \left(\sum_{u \in \mathcal{N}(v) \cup \{v\}} \alpha_{uv}^{(l)} \mathbf{W}^{(l)} \mathbf{h}_u^{(l)} \right). \quad (2-4)$$

其中：

$\alpha_{uv}^{(l)}$ 是注意力权重，计算为：

$$\alpha_{uv}^{(l)} = \frac{\exp \left(\text{LeakyReLU} \left(\mathbf{a}^T \left[\mathbf{W}^{(l)} \mathbf{h}_u^{(l)} \parallel \mathbf{W}^{(l)} \mathbf{h}_v^{(l)} \right] \right) \right)}{\sum_{w \in \mathcal{N}(v) \cup \{v\}} \exp \left(\text{LeakyReLU} \left(\mathbf{a}^T \left[\mathbf{W}^{(l)} \mathbf{h}_w^{(l)} \parallel \mathbf{W}^{(l)} \mathbf{h}_v^{(l)} \right] \right) \right)}. \quad (2-5)$$

$\mathbf{a}$ 是可训练的注意力向量。

通过注意力机制，尽管未显式输入空间距离，但 K 近邻图的构建已隐含了“邻近节点更可能相关”的假设。模型通过注意力机制进一步筛选出拓扑邻近中真正重要的边。

而在训练过程中，模型通过反向传播优化注意力权重，使高权重边逐渐与任务相关的隐含空间结构对齐（如纳米体的真实空间分布）。

最后，将节点级别的表示聚合为图级别的表示。

2.2 硬件配置

本次实验的硬件配置如表 4-1 所示，其中，GPU 为 3090(24GB)*8，系统是 CentOS 7.5，内存为 DDR4 32G*4=128G。这为深度学习模型的训练和分析提供了强大的计算能力和存储支持。

表 4-1 硬件配置

GPU	GPU02 3090(24GB)*8
系统	CentOS 7.5
内存	DDR4 32G*4=128G

2.3 软件配置

在本次实验的硬件配置如表 4-2 所示，其中，操作系统为 Linux x86_64，编程语言选用 Python 3.9，深度学习框架为 PyTorch 12.1。这些软件配置为实验提供了一个稳定而高效的开发环境。

表 4-2 软件配置

操作系统	Linux	x86_64
编程语言	Python	3.9
深度学习框架	PyTorch	12.1

2.4 PyTorch 深度学习框架

PyTorch 是一个广泛使用的开源深度学习框架，以其灵活性和高效性著称。在本项目中，PyTorch 为图神经网络（GNN）的构建和训练提供了坚实的基础，用来处理复杂的纳米抗体图结构数据。具体而言，通过基于 PyTorch 的图神经网络库 PyTorch Geometric 中的 EdgeConv 模块和 GATConv 注意力机制，从而有效捕捉纳米抗体中氨基酸残基之间的关系。

2.5 PyMol 分子可视化软件

PyMOL 是一款功能强大的开源分子可视化软件，能够生成高质量的蛋白质和小分子三维结构图像。使用处理 PDB 文件时，PyMOL 可以自动检查氨基酸残基是否属于 20 种标准氨基酸（如 ALA、GLY 等），过滤掉非标准残基和缺少 α

碳（CA）的残基。通过内置字典或自定义脚本，还可以将未知残基（UNK）标记为"X"，精准提取主链原子（N、CA、C）的坐标，获取坐标数据。若序列长度超过预设值，也可通过截断操作限制处理范围。

在本研究中，通过熟练使用 PyMol 进行数据处理，确保纳米抗体数据集的顺利构建。

2.6 AntiBERTy 抗体预训练模型库

AntiBERTy 是 RosettaCommons 团队开发的抗体预训练语言模型，其中，如 IgGM、DeepNano 能够生成高亲和力的纳米抗体序列并优化其 CDR 区域，提高结合特异性，例如 IgGM 模型可同时预测纳米抗体的序列和结构，DeepNano 模型分析纳米抗体-抗原相互作用精准预测结合表位。

在本研究中，数据输入为抗体的氨基酸序列通过特殊标记区分序列类型和位置，通过 AntiBERTy 以其生成高亲和力的纳米抗体序列，优化其 CDR 区域，提高结合特异性的特点，为实验提供预训练模型，促进精准预测结合表位，辅助靶向治疗设计。

3. NanoKGAT 模型

3.1 模型概述与架构

NanoKGAT 是基于图神经网络 (GNN) 的模型提出的, 专为处理纳米抗体结构数据的模型。该模型通过三层一维图卷积和注意力机制, 捕捉纳米抗体中氨基酸残基之间的复杂关系, 从而实现对纳米抗体结构的预测或分类任务。

图神经网络 (GNNs) 分为递归图神经网络 (RecGNNs)、卷积图神经网络 (ConvGNNs)、图自编码器 (GAEs) 和时空图神经网络 (STGNNs)。RecGNNs 顾名思义, 通过循环神经体系结构学习节点表示。展开来说, RecGNNs 假设图中的节点不断与其邻居交换信息, 每次得到新的信息就将该信息扩散给周围的邻居节点, 通过多次循环往复直到达到稳定的平衡。ConvGNNs 的主要思想是通过汇总节点自身的特征和邻居的特征来生成节点的表现形式。而且通常 ConvGNNs 会进行多次图卷积来关注更多的特征。与 RecGNNs 相比, ConvGNNs 堆叠了多个图卷积层来提取高级节点的表示。GAEs 是无监督学习的框架, 它将节点或图编码到潜在的矢量空间中, 并从编码后的信息中重建图数据, 这多用于学习网络嵌入和图生成分布, 通过重建图结构信息来学习潜在节点表示, GAEs 既可以逐步生成图的节点和边, 也可一次性输出所有的图。STGNNs 是针对时空图来训练学习的, 同时考虑空间依赖性和时间依赖性, 更多的还是用在交通领域。

基于我们自身纳米抗体结构数据的表示, 以及抗体旁位受周围区域分子原子的影响, 以及其更多关注空间上的依赖的原因, 在 NanoKGAT 模型架构构建上, 我们选择了 ConvGNNs 图卷积层来作为处理数据。特别地, ConvGNNs 通常使用 2~5 层图卷积, 多次卷积达到更好的效果。于是我们选取 3 层卷积更多捕获节点和边的联系。图卷积层在维度上也有差异, 比如二维 (2D) 卷积, 内核在数据上沿着二维滑动, 通常用于图像处理。那么显然, 一维卷积 (1D) 就是内核沿着一维滑动。维度不是越高越好, 这需要考虑数据的特性, 通常时间序列相关的数据非常适用于一维卷积, 此外声音和文本数据也可以用一维卷积层进行处理。三维卷积 (3D) ——内核在 3D 数据上滑动, 像 3D 成像图像处理, 核磁共振扫描就与三维卷积匹配度更高。对此, 对纳米抗体图结构数据进行分析, 由于我们将纳米抗体数据的结构处理为带有节点和边的矢量图, 可以理解为类似社交网络图

（节点关系如图 3-1 表示），那么在卷积上其实对维度的要求没有非常高，最终选择了将输入数据集进行 3 次 1D 卷积，这也是希望通过 3 次图卷积能够得到更好的模型效果。




图 3-1 节点矢量关系图示例

由于在神经网络中，每个层的输出都是通过对前一层输出的非线性变换得到的。但是，当网络的深度增加时，前一层的输出可能会被过度压缩或拉伸，导致信息丢失或重复。这种情况下，网络的性能可能会受到影响，同时也会出现梯度消失或梯度爆炸的问题。为了解决这个问题，在 3 次 1D 卷积层之后我们引入残差层进行残差连接。所谓的残差连接就是将前一层的输出直接添加到当前层的输出中，可以理解为将上个阶段的“结果”加到这个阶段来，以此更好地进行学习模型学习。总的来说，它可以帮助信息在深层网络中流动，并解决梯度消失和梯度爆炸的问题。进行残差连接后，采用 EdgeConv 和 GATConv（Graph Attention Convolution）两种图形卷积机制进行特征学习。EdgeConv 是“动态图边卷积网络”，之前的图边卷积网络普遍倾向于搜索网络的线索和一致性，没有过多关注像角点和边缘点这样显著的特征。但仅仅通过传统方法如计算或者微分这类的方法提取网络信息在纳米抗体旁位预测上显然不够用，所以需要更多地基于学习的方法去增强了节点之间的边信息。于是引入 EdgeConv，捕获局部的关键信息，强调出邻居节点的重要性。此外，常用的图卷积层有 GraphConv、GATConv 和 SAGEConv，功能比较类似的，都是用来学习图结构数据中的节点表示，以便于后续的图分析任务，比如说节点分类、图分类或链接预测等等。这三者区别在于怎么聚合邻接节点的信息：GraphConv 采用平均池化，GATConv 通过注意力机制赋予不同邻居不同的重要性，而 SAGEConv 则提供了多种聚合函数选择。这些差异影响了导致训练出来的模型有不同的表现。在纳米抗体的旁位预测中，我

们更多关注分子与分子、原子与原子之间的关系，最终选择 GATConv，讲残差连接后的结果进行图卷积。GATConv 通过注意力机制动态调整不同残基的权重，这能进一步提升了模型的预测精度。

神经网络核心在于它们能够学习训练数据中的表示，以及如何将其与想要预测的输出变量联系起来。而传统的感知机只有输入和输出层，这两层共同组成了一个简单的神经元。首先加权输入信号，然后使用激活功能，最终产生输出信号。但当数据不再是线性数据的时候，传统的感知机就不能在二分类模型中取得很好的效果，因此可以加深这个神经元的网络层次，也就是使用多层感知机来进行输入输出的映射。至此，整个 NanoKGAT 模型的架构构建完毕。

模型的整体结构如图 3-2 所示。




图 3-2 NanoKGAT 模型架构

3.2 与其他模型的异同点

Antibody i patch^[21]是相对早期（2010-2013）的抗体抗原相互作用预测方法，Antibody i patch 结合位点预测算法通过输入两个会与其同源物的 MSA（Multiple Sequence Alignment）相互作用的蛋白质，最终判定这两个蛋白质是否会相互作用。MSA 指的是多序列比对，通常输入是多个相似的 DNA 或蛋白质序列，通过在每个序列的不同位置插入尽量少的空格，使得多个序列具有相同的长度，叠放在一起表现出最大的相似性。而由于抗体-抗原复合物的形成过程与标准的蛋白质-蛋白质相互作用过程截然不同，因此不可能产生相应的 MSA。所以，Antibody i patch 还在有 MSA 和没有 MSA 的情况下对其最初的蛋白质-蛋白质结合位点预测数据集评估两种输入结果之间差异的统计意义。此外，由于抗体抗原相互作用会受到各自残基的影响。因此，Antibody i patch 评分系统在抗体和抗原之间具有不对称性。它提出 iPatch 值的概念，用来衡量结合可能性。根据 IMGT 定义，计算出每个 CDR 区域加上两侧两个残基的抗体 iPatch 值，抗体结合位点的大部分是由 CDR 和两侧的几个残基组成的。iPatch 分数。分值没有标准化，范围在 0 到 300 之间，分值越高，结合可能性越大。

与 Antibody i patch 相比，NanoKGAT 重点关注 Nanobody 纳米抗体与抗原之间的相互作用概率，也关注 CDR 区域以及它附近的残基，但 NanoKGAT 关注的残基数量更多，并且用 KNN 近邻算法对不同距离的残基赋予了不同的权值，使用注意力机制在邻居节点之间交流信息，得到更好的效果。

CNNs Linked With GCNs for Paratope Prediction^[4]（记为 CNN Linked With GCNs）是 2021 年提取的根据序列和结构的特征来识别抗体的氨基酸残基与其相关抗原直接相互作用的方法。该算法使用与图卷积网络（GCN）链接的卷积神经网络（CNN）来利用来自顺序和空间邻居的信息来更多地了解目标氨基酸残基的局部环境。CNN Linked With GCNs 的模型架构如图 3-3 所示。




图 3-3 CNNs Linked With GCNs for Paratope Prediction 模型架构

CNN Linked With GCNs 与 NanoKGAT 模型相比，都是在设计上融合了 CNN 和 GCN 的一些经典元素，同时也引入了图神经网络（GNN）特有的组件。以下是 NanoKGAT 模型与 CNN Linked With GCNs 的相似点和不同点。

在卷积层的使用上，两者都使用了卷积层。但 CNN Linked With GCNs 使用了二维卷积层（2D Convolution）来处理图像数据，通过滑动窗口的方式捕获局部特征。而 NanoKGAT 模型则使用了一维卷积层（1D Convolution）来处理节点特征，还引入 EdgeConv，专门用于处理图结构数据，捕捉了数据中的局部特征。特别地，NanoKGAT 还在图卷积层中使用了多种聚合器，如均值、求和、标准差、最大值、最小值来综合考虑节点邻居的特征。两个模型都引入了图注意力网络（Graph Attention Networks, GAT），NanoKGAT 动态地为节点分配不同的注意力权重是本模型最大的特点。这种机制能够更准确地捕捉节点间的依赖关系，这是图神经网络特有的组件。

在数据表示上，CNN Linked With GCNs 处理的是规则网格数据。而 NanoKGAT 专门针对图结构数据，对其中节点和边的不规则的结构和连接关系进行处理。这种数据表示方式与 CNN Linked With GCNs 有本质的不同。此外，NanoKGAT 使用残差连接（Residual Connections）将卷积层的输出与输入相加，缓解深层网络的梯度消失，促进梯度流动，而 CNN Linked With GCNs 没有使用残差连接。在 NanoKGAT 模型的最后阶段，我们还使用了一个多层感知机用于将高维特征压缩到低维空间，并进行最终的分类或回归，将图卷积的结果和注意

力层的输出映射到最终的旁位预测结果上。

2023 年, 研究人员提出基于比对语言的可微配对模型 (DiffPALM), 该方法通过利用 MSA Transformer 利用周围环境在多个序列比对中填充掩蔽氨基酸 (也就是掩码模型的拓展) 来学习蛋白质序列。掩码语言模型 (Masked Language Model, 简称 MLM) [3], 一开始更多的是应用在自然语言处理上。MLM 的核心思想是通过随机掩盖输入文本中的部分词语, 并训练模型根据上下文预测被掩盖的词语, 从而学习语言的深层表示, 具体架构如图 3-4 所示。MLM 的后来, 引入到配对相互作用的蛋白质序列领域。MLM 利用了多个序列比对 (MSA) 上训练的蛋白质语言模型, 例如 MSA Transformer 和 AlphaFold 的 EvoFormer 模块, 解决了两个蛋白质家族的旁系同源物之间配对相互作用的问题。DiffPALM 依赖于 MSA Transformer 而无需微调, 在从普遍存在的蛋白质数据集中提取的多序列比对上, DiffPALM 优于现有的基于协同进化的配对方法。

NanoKGAT 引入 MLM 进行自监督预训练, 随机遮蔽 15% 的氨基酸残基, 模型需要根据其前后氨基酸的上下文信息来预测被遮蔽的部分。这使得模型能够学习到双向的语义依赖关系, 从而更好地理解序列的整体结构和功能, 从而提升模型的学习能力和泛化能力。




图 3-4 掩码语言模型示例

综上，该图神经网络模型在设计上借鉴了 CNN Linked With GCNs，使得模型保留了传统深度学习模型的优点。然而，它也引入了图神经网络特有的组件，例如图卷积层和图注意力机制，以处理图结构数据，导入了 MLM 语言模型提升对蛋白质序列的理解。这些不同点使得模型能够有效地处理复杂的图数据，并在纳米抗体结合位点分析等任务中表现出色。通过结合传统和图神经网络的优点，模型在处理复杂生物分子结构时具有显著的优势。

4. 模型训练与评估

4.1 纳米抗体数据来源与格式

为了获取到适用于纳米抗体领域的预训练数据集，我们从抗体数据库 RCSB PDB 收集了纳米抗体数据，作为 dataset1，并从过往研究中提取了 PECAN 的数据集，整合为 dataset2 作为对照组，研究图神经网络在多个抗体结合位点数据集上的效果。

其中，数据格式为 PDB（Protein Data Bank）。PDB 数据格式是一种标准化的文件格式，用于存储生物大分子（如蛋白质、核酸和多糖）的三维结构信息。一个典型的 PDB 文件由多个记录（records）组成，每个记录由固定的 80 个字符组成。这些记录被组织成不同的部分，每个部分描述了分子结构的不同方面。

与本研究强相关的信息如下图 5-1 所示：红色区域为 Nano_chain，蛋白质分子的纳米抗体区域；蓝色区域为 Antigen_chain，蛋白质分子的抗原区域；黄色区域为 CDR，抗体抗原结合区域。




图 5-1 抗体抗原及其 CDR 结合区域

4.2 基于纳米抗体结构的特征向量数据集构建

提取纳米抗体结构的方法有 PDB 代码解析，AlphaFold3、IgFold、扩散模型、距离几何法等。每种方法的侧重点不同，输入输出也存在差别。在经过对这几种提取方法的对比总结（如表 5-1 所示）以及自身研究的需要，我们选取了 PDB 代码解析。

表 5-1 PDB 模块解析其他提取方法对比总结

方法	输入	输出范围	速度	精度 (RMSD)	适用场景
PDB 解析 (代码)	PDB 文件	实验测定坐标	秒级	实验精度	结构分析、基准验证
AlphaFold3	序列 /MSA	全局结构	小时级	0.5–1.5Å	通用蛋白/复合物预测
IgFold	抗体序列	抗体骨架	<1 分钟	1.0–2.5Å (CDR)	抗体设计
扩散模型	2D 图/噪声	多样构象	分钟级	1.0–3.0Å	小分子/局部构象生成
距离几何法	距离矩阵	粗略结构	秒级	2.0–5.0Å	快速初筛

数据处理流程如图 5-2 所示。使用 Bio.PDB 模块进行文件解析，使用 PDBParser 解析 PDB 文件，获取蛋白质结构对象。从 PDB 文件中提取蛋白质骨架原子的三维坐标。再从氨基酸序列中提取每个残基的高维嵌入向量，在本例我们选取 512 作为嵌入向量的维度，使用 AntiBERTyRunner 对氨基酸序列进行序列嵌入，将氨基酸序列转换为高维的向量表示。这些向量包含了残基的语义信息，并将其赋值给图数据对象的 x 属性，作为节点特征。这些嵌入向量通过预训练的抗体语言模型（如 AntiBERTy）获得接着，遍历指定链的残基，过滤非标准氨基酸（如 UNK）和缺少 α 碳（CA）的残基，生成氨基酸序列。针对每个残基的骨架原子（BACKBONE_ATOMS，通常为 N、CA、C、O）获取其三维坐标，存储为 $3 \times n$ 矩阵（n 为残基数）。甘氨酸（G）无侧链原子（CB），需特殊处理。若原子缺失，填充 NaN 并报错。最后，根据复合物结构中残基之间的距离原中的每个残基都被标记为旁位(阳性类)或非旁位(阴性类)。对于每个纳米抗体，保留可变区 Fv 序列和重链结构信息，删除重复序列。




图 5-2 3zdy 结构的处理流程

接下来，我们使用 K-近邻 (K-NN) 算法选取 8 作为近邻的数量，根据每个残基的三维坐标构建图的边索引。边索引是一个二维张量，表示图中节点之间的连接关系，通过它在图结构中反映纳米抗体的三维结构信息。

在蛋白质的序列规格统一上，我们使用一个掩码 Mask，其值为有效序列的长度（在本例中为 140）。如果序列长度小于 140，则使用零向量进行填充，以确保每个序列的长度固定为 140；如果长度大于 140，则截断多余的标签，只保留前 140 个标签；通过这个掩码进行填充和截断，确保数据规格的统一性，处理流程如图 5-3 所示/

最后，将所有这些组件组合成一个完整的图数据对象。这个对象封装了纳米抗体的所有必要信息，使其能够被图神经网络模型有效地读取和处理，从而进行旁位预测任务。

模型预期数据是，对每个样本输出一个概率值，范围在[0,1]，表示该样本属于正类（如阳性或目标类别）的置信度。对应的真实标签为二进制值（0 或 1），标记样本的实际类别，表示每个氨基酸残基是否为旁位区域（1 表示旁位，0 表示非旁位）。




图 5-3 NanoKGAT 模型输入输出数据流程图

表 5-3 数据集情况说明

数据集	训练集	测试集	验证集
Dataset1	5000	625	625
Dataset2	5200	650	650

最后，如表 5-3 所示，将 dataset1、dataset2 数据按照 8: 1: 1 的比例分成训练集、测试集和验证集，其中训练集含有 5000 个纳米抗体蛋白质，测试集和验证集各 625 个纳米抗体蛋白质，具体数据集内容如表 5-2 所示例。

表 5-2 部分数据集展示

PDB	Sequence	Paratope_labels	Nano_chain	Antigen_chain	Coord
5van	VQLVESG	[N, N, N, N, N, N,	B	anti A	[[20.42900
	GGLVQAG	N, N, N, N, N, N,			085449218
	GSLRLS...	N...			8,24.5289...
7n0u	VQLQESG	[N, N, N, N, N, N,	H	anti C	[[50.44400
	PGLVKPSE	N, N, N, N, N, N,			024414062
	TLSLTC...	N...			5,69.4720...
7x94	QVQLVQS	[P, P, N, N, N, N,	H	anti A	[[53.52899
	GSELKKP	N, N, N, N, N, N,			932861328,
	GASVKI...	N, N, N ...			48...
.....					

4.3 模型权重文件的训练与保存

对于每一个模型，神经网络各层的权值不同，而这个权值是通过训练集训练出来的。也就是说，当我们通过训练集对模型进行训练后，会得到相对应的网络各层的权重。在应用时，只需要加载权重即可，这样的—个文件就是我们的模型权重文件。

在模型的训练过程当中我们往往通过输出中间层次的指标来帮助我们及时的了解与调整模型。当我们发现验证集的性能不再提升的时候，可以提早停止训练，减少成本投入。当训练数据的训练结果相对较为单一，也可以通过对训练数据进行随机变换。训练完成后，将训练好的模型权重文件及时保存，用于后续的应用与评估。

4.4 模型评估方法

通过 ROC 曲线和 PR 曲线评估模型性能，具体方法如下：

1) 术语解析

在二分类问题当中，可根据样例真实类别与模型预测类别的组合划分为表中四种情形，而这四种情形可汇总为一个混淆矩阵情形分析表。混淆矩阵显示了分类模型在进行预测时会对哪一部分进行混淆，这可以帮助我们了解分类模型所犯的错误。

表 6-1 TP、FP、TN、FN 术语解析

术语	全称	解释
TP (True Positive)	真阳性	模型正确预测为正类的样本数
FP(False Positive)	假阳性	模型错误预测为正类的负类样本数
TN (True Negative)	真阴性	模型正确预测为负类的样本数
FN(False Negative)	假阴性	模型错误预测为负类的正类样本数

2) ROC 曲线与 AUC

对于 ROC 曲线，横轴为假阳性率（FPR），纵轴为真阳性率（TPR），ROC

曲线下的面积为 AUC。对角线对应“随机猜测”模型，此时即 $AUC = 0.5$ ；当模型的预测结果越靠近 (0, 1) 这个点的时候，也就是 $AUC > 0.9$ 则证明模型的效果越好。

计算公式如下：

$$FPR = \frac{FR}{FP+FN}, TPR = \frac{TP}{TP+FN}. \quad (6-1)$$

若一个模型的 ROC 曲线被另一个模型的曲线完全“包住”，则可断言后者的性能优于前者，若两个模型的 ROC 曲线发生交叉，则难以一般性地断言两者孰优孰劣。此时如果一定要进行比较，则较为合理的判据是比较 ROC 曲线下的面积。

3) PR 曲线

很多情况下，可根据模型的预测结果对样例进行排序，通常将模型认为最可能是正例的样本排在前面。按这种排序进行预测，则可以算出当前的精确率和召回率。此时，以精确率为纵轴，召回率为横轴，就得到了精确率-召回率曲线，也就是 PR (Precision Recall) 曲线。PR 曲线上的一个点代表在当前的阈值下大于该阈值的结果为正样本，小于该阈值的结果为负样本返回，此时对应的召回率和精确率。计算公式如下：

$$Precision = \frac{TP}{TP+FP}, Recall = \frac{TP}{TP+FN}. \quad (6-2)$$

该曲线直观地显示出模型在样本总体上的召回率、精确率。在进行比较时，若一个模型的 P-R 曲线被另一个模型的曲线完全“包住”，则可断言后者的性能优于前者，

4) F-Score 分数

在不同的场景下，对精确率和召回率的重视程度有所不同，而 F-Score 就是衡量综合考虑精确率和召回率的指标，是基于精确率与召回率的调和平均，对精确率与召回率进行平均的一个结果。

标准 F1-Score 计算公式如下：

$$F_1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} = \frac{2 \cdot TP}{2 \cdot TP + FP + FN}. \quad (6-3)$$

F1-Score 的取值范围为[0,1]，越接近 1 表示模型性能越好。

5) MCC (Matthews Correlation Coefficient)

MCC 曲线适用于类别不平衡的数据集是用于评估二分类模型性能的综合指标，它通过混淆矩阵中计算得出，取值范围为[-1,1]。当 MCC 为+1 的时候表示模型预测结果与真实标签完全一致（完美分类器）；如果 MCC 介于 0.5 和 1 之间，通常认为模型性能良好，值越接近 1 性能越优；MCC 等于 0 则表示模型预测效果等同于随机猜测；如果 MCC 小于 0，则表明型预测结果比随机猜测更差，负值绝对值越大性能越差（完全反向预测时为-1）。

计算公式如下：

$$MCC = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP+FP)(TP+FN)(TN+FP)(TN+FN)}}. \quad (6-4)$$

MCC 是一个综合性能指标，考虑了真正例、真反例、假正例和假反例，通过一个复杂的公式计算得出。而 F1-Score 是精确率和召回率的调和平均值，表示了模型在平衡了预测的精确性和覆盖率后的表现。MCC 考虑了所有四个值（TP、TN、FP、FN），因此适用于存在类别不平衡的数据集，其中一个类别可能比另一个类别更常见。特别是希望评估模型性能而不受类别分布影响时，MCC 非常有用。

6) 阈值选择的影响

阈值的作用是将概率值转换为二分类标签。阈值介于 0 到 1 之间。如果阈值过高，到达 0.8，则误报（FP）降低，但可能漏检（FN）；如果阈值设定过于低，如 0.5，则召回率会升高（TP）但可能误报（FP）。

本论文选择 0.6 作为阈值进行模型评估，重点关注 0.6 阈值下的模型评估。

4.5 实验结果分析

一个比较好的损失曲线变化图，在训练开始阶段，损失值下降幅度会比较大，如果下降幅度比较大，说明学习率合适且正在进行梯度下降。当学习到一定的过

程后，损失函数会趋于平稳，损失变化没有一开始那么明显。如果曲线当中出现的毛刺较多，是因为 `better size` 的关系，`better size` 设置的越大，毛刺越小。如果一个损失函数变化趋势并不明显，但曲线仍然在慢慢下降，这个过程中是一个调整的过程，但总体趋势是对的。

如果损失函数不停的上下浮动，并且没有整体呈下降的幅度，这证明在这个学习过程当中，并没有进行有效学习。在训练损失和验证损失趋向于平缓的时候，如果验证损失高于训练损失，则是典型的过拟合现象。也就是说，最后训练损失与验证损失要趋于一致并且平缓。

在 `dataset1` 上，选取 `batch_size` 为 8，在实验过程中选择 `epoch` 为 20, 100, 150, 200 四种情况，进行模型训练，模型训练结果如图 6-1 所示。




图 6-1 不同 `epoch` 下的训练模型损失函数 (`batch_size` 为 8)

这张图表展示了模型在不同训练轮数 (`Epoch=20/100/150/200`) 下训练损失 (`Training Loss`) 和验证损失 (`Validation Loss`) 的动态变化。

可以看到，在训练开始阶段，损失值确实符合下降幅度较大，特别是在 `epoch` 不是很大的情况下。而 `epoch` 为 200 的时候，可以明显的看出此时的损失函数，验证损失远超训练损失，并且不停的上下浮动，这显然不是一个较好的学习过程。对比中间两幅图像，当 `epoch` 为 100 的时候，显然曲线的毛刺更少，振幅也更小。

对此，得出以下结论。

在 `batch_size` 为 8 的时候，选择 `epoch` 为 100 左右且小于 100 较为合适。

根据上述分析，将 `epoch` 设置为 80，再次进行模型训练，训练结果如图 6-2 所示。模型表现出良好的收敛性和稳定性，满足上面提到的一个较好的损失函数变化图的判断。




图 6-2 epoch 为 80 下的训练模型损失函数（`batch_size` 为 8）

此时，改变 `batch_size` 为 32，同样选取 `epoch` 为 20, 100, 150, 200 四种情况，进行模型训练，模型训练结果如图 6-3 所示。




图 6-3 不同 epoch 下的训练模型损失函数（`batch_size` 为 32）

运用同样的方法进行分析。此时，同样将 `epoch` 设置为 80，再次进行模型训练，训练结果如图 6-4 所示。




图 6-4 epoch 为 80 下的训练模型损失函数（batch_size 为 32）

比较 batch_size 为 8，32 两种情况下的模型损失函数，得到异同点。

相同的是，两者的均呈现典型的“快速下降→平稳收敛”模式，最终训练/验证损失差值均小于 0.005，表明模型容量适中。

不同的是，早期训练过程中，图 6-2（记为曲线一）没有显著震荡，而图 6-4（记为曲线二）中，当 epoch 为 5-15 验证损失波动明显。在过拟合的风险上，曲线一极低，即两条曲线完全重合，图线二则存在轻微过拟合倾向。在数据敏感性上，曲线一在数据分布更具备鲁棒性，不容易受初始权重或学习率的较大影响。

综上，最终选取 batch_size 为 8，epoch 为 80 训练出来的模型作为最终模型，保存模型权重文件。

接着，通过 ROC 曲线和 PR 曲线评估模型性能。

评估结果如图 6-5 所示。

其中：

ROC AUC: 0.89，根据模型性能较好。

PR AP: 0.81，模型性能较好。




图 6-5 ROC 曲线和 PR 曲线

现对 dataset2 用同样的方式进行分析，选取合适的 batch_size 和 epoch 之后（此次分析得到的结论与 dataset1 相似，于是不再赘述）。

相比于 dataset1，通过增加补充 PECAN 数据后形成 dataset2 的效果有所提高，由此验证了模型的泛化性，更加科学。

5. 模型对比与未来展望

5.1 研究总结与模型对比

本研究全面介绍了图神经网络算法在纳米抗体结合位点的数据集上的应用，针对纳米抗体的结构特征，探讨了纳米抗体图结构表示方法，构造用于图神经网络的纳米抗体数据集，在传统卷积神经网络的基础上，创造性引入 K 近邻，图网络注意力(Graph Attention Network)机制，构建了 NanoKGAT 模型。通过使用控制变量法，调整模型训练的参数，比对不同参数下的模型性能，得出较为可行可靠的纳米抗体旁位预测模型。

为了更好地了解该模型的优劣，我们专门对最后一层的图形注意力网络卷积层进行了分析。主要的使用方法是提取连接到 GAT 层节点的边缘注意力权重。我们注意到，虽然我们模型中的边缘被定义为 K 个最近的邻居，但我们并没有明确输入最近边缘的排名信息。相反，我们只将 K 条最近的边视为图中节点的边。模型为某些边缘分配了较高的关注度。因此，在我们的模型中，注意力系数较大的边缘往往连接两个相邻节点，表明该模型学习了数据的空间结构。这一发现表明，即使没有明确提供纳米体的空间结构，模型也能辨别空间距离并将其作为评估标准。此外，我们还关注了具体的纳米抗体蛋白质分子在该模型上的预测结果。结果显示，在具体的纳米抗体蛋白质的旁位预测上，模型没有具体的可视化手段。未来在该领域的研究可以朝着更加明确、科学的方向发展。

此外，本研究还对抗体旁位的预测，对比了各类旁位预测方法。结果如下表 6-2 所示。

表 6-2 旁位预测方法的比较

方法	ROC AUC	PR AUC
Antibody i patch(2013)	0.626	0.380
Daberdaku (2019)	0.545	0.923
Parapred (2018)	0.646	0.930
PECAN (2020)	0.675	0.952
Paragraph(2022)	0.696	0.934
NanoKGAT(dataset1)	0.890	0.810
NanoKGAT(dataset2)	0.900	0.880

据表格数据显示，NanoKGAT 在 PR AUC 为 0.880，高于其他的方法 PR AUC，

这表明该方法在正样本的预测精度上表现极其出色。同时，与其他方法相比，NanoKGAT 预测模型的 ROC AUC 较低，表明在区分正负样本方面可能存在一定的不足。

综上，当我们需要较高精度的正样本预测，推荐使用 NanoKGAT；整体分类性能优异，可优先考虑 PECAN(2020)或 Paragraph(2022)。

5.2 未来展望

此外，对在各个分类阈值上的 F-Score 分数和 MCC 性能指标评估，结果如下图所示。

其中，阈值约为 0.6-0.8 的区间内，F-Score 和 MCC 均跃升至约 0.8，模型性能显著提升，表明模型在此范围内能有效平衡精确率和召回率，且 MCC 接近 1，即对样本的判别具有高可靠性。这一阈值区间可作为实际应用的优选参数。但低阈值区间（0-0.6）性能较差，如 F-Score 和 MCC 均低于 0.2，说明模型对低置信度样本的预测能力不足，可能因训练数据分布不均或特征区分度不足导致。高阈值区间（ >0.8 ）性能骤降，表示模型过于保守，漏检率增加（召回率下降），需调整分类策略或引入更鲁棒的特征。




图 6-6 F-Score 曲线和 MCC 曲线

最后，在纳米抗体旁位预测任务中，传统的抗体旁位预测模型表现出有限的性能。而研究结果表明，尽管存在不足，但可用于预测纳米抗体-抗原配位的深度学习模型 NanoKGAT 模型仍较好地捕捉到了纳米抗体的结构特征，并在纳米抗体表位预测任务中取得了较好的性能，取得了巨大进步。此外，本研究相关代码可通过 <https://github.com/mopppppp/Analysis-and-evaluation-of-GNN-algorithms-on-multiple-antibody-binding-site-datasets/>获取。

参考文献

- [1]Cai H, Zhang Z, Wang M, Zhong B, Li Q, Zhong Y, Wu Y, Ying T, Tang J. Pretrainable geometric graph neural network for antibody affinity maturation. *Nat Commun.* 2024 Sep 6;15(1):7785. doi: 10.1038/s41466-024-51563-8. Erratum in: *Nat Commun.* 2024 Oct 7;15(1):8675. doi: 10.1038/s41466-024-52886-1. PMID: 39242604; PMCID: PMC11379722.
- [2]Chinery L, Wahome N, Moal I, Deane CM. Paragraph-antibody paratope prediction using graph neural networks with minimal feature vectors. *Bioinformatics.* 2023 Jan 1;39(1):btac732. doi: 10.1093/bioinformatics/btac732. PMID: 36370083.
- [3]Lupo U, Sgarbossa D, Bitbol A F. Pairing interacting protein sequences using masked language modeling[J]. *Proceedings of the National Academy of Sciences*, 2024, 121(27): e2311887121.
- [4]Lu S, Li Y, Wang F, et al. Leveraging sequential and spatial neighbors information by using CNNs linked with GCNs for paratope prediction[J]. *IEEE/ACM Transactions on Computational Biology and Bioinformatics*, 2021, 19(1): 68-74.
- [5]Quadrini M, Ferrari C. Exploiting the Role of Features for Antigens-Antibodies Interaction Site Prediction. *Methods Mol Biol.* 2024;2780:303-325. doi: 10.1007/978-1-0716-3985-6_16. PMID: 38987475.
- [6]Lu S, Li Y, Wang F, Nan X, Zhang S. Leveraging Sequential and Spatial Neighbors Information by Using CNNs Linked With GCNs for Paratope Prediction. *IEEE/ACM Trans Comput Biol Bioinform.* 2022 Jan-Feb;19(1):68-74. doi: 10.1109/TCBB.2021.3083001. Epub 2022 Feb 3. PMID: 34029193.
- [7]Zhang X, Wang H, Sun C. BiSpec Pairwise AI: guiding the selection of bispecific antibody target combinations with pairwise learning and GPT augmentation. *J Cancer Res Clin Oncol.* 2024 May 7;150(5):237. doi: 10.1007/s00432-024-05740-3. PMID: 38713378; PMCID: PMC11076393.
- [8]Beghein E, Gettemans J. Nanobody Technology: A Versatile Toolkit for Microscopic Imaging, Protein-Protein Interaction Analysis, and Protein Function Exploration. *Front Immunol.* 2017 Jul 4;8:771. doi: 10.3389/fimmu.2017.00771. PMID: 28725224; PMCID: PMC5495861.
- [9]Bessalah S, Jebahi S, Mejri N, Salhi I, Khorchani T, Hammadi M. Perspective on therapeutic and diagnostic potential of camel nanobodies for coronavirus disease-19 (COVID-19). *3 Biotech.* 2021 Feb;11(2):89. doi: 10.1007/s13205-021-02646-5. Epub 2021 Jan 22. PMID: 33500874; PMCID: PMC7820838.
- [10]Wilton EE, Opyr MP, Kailasam S, Kothe RF, Wieden HJ. sdAb-DB: The Single Domain Antibody Database. *ACS Synth Biol.* 2018 Nov 16;7(11):2480-2484. doi: 10.1021/acssynbio.8b00407. PMID: 30441908.

- [11]Kipf T N , Welling M . Semi-Supervised Classification with Graph Convolutional Networks[Js2016.
- [12]W. Hamilton, Z. Ying and J. Leskovec, “Inductive representation learning on large graphs” in Advances in Neural Information Processing Systems, pp. 1025-1035, 2017.
- [13]Eberhardt,J. et al. (2021) AutoDock vina 1.2.0: new docking methods,expanded force field, and python bindings. J. Chem. Inf. Model., 61,3891–3898.
- [14]Liberis E, Velickovic P, Sormanni P, Vendruscolo M, Liò P. Parapred: antibody paratope prediction using convolutional and recurrent neural networks. Bioinformatics. 2018 Sep 1;34(17):2944-2950. doi: 10.1093/bioinformatics/bty305. PMID: 29672675.
- [15]Jeffrey A Ruffolo, Jeffrey J Gray, and Jeremias Sulam. Deciphering antibody affinity maturation with language models and weakly supervised learning. arXiv preprint arXiv:2112.07782, 2021.
- [16]Tailor, Shyam A., et al. "Do we need anisotropic graph neural networks?." arXiv preprint arXiv:2104.01481 (2021).
- [17]Moonens K, Gideonsson P, Subedi S, et al. "Structural Insights into Polymorphic A]BO Glycan Binding by Helicobacter pylori." Cell Host & Microbe. 2016 Jan;19(1):55-66.
- [18]Sciara G, Bebeacua C, Bron P, et al. "Structure of lactococcal phage p2 baseplate and its mechanism of activation." Proceedings of the National Academy of Sciences of the United States of America. 2010 Apr;107(15):6852-6857.
- [19]Ahmed Elnaggar, Michael Heinzinger, Christian Dallago, Ghalia Rehawi, Yu Wang, Llion Jones, Tom Gibbs, Tamas Feher, Christoph Angerer, Martin Steinegger, Debsindhu Bhowmik, Burkhard Rost. "ProtTrans: Towards Cracking the Language of Life’s Code Through Self-Supervised Deep Learning and High Performance Computing." bioRxiv. 2020 Jul 12;2020.07.12.199554.
- [20]Liu Y, Ott M, Goyal N, et al. "Roberta: A robustly optimized bert pretraining approach." arXiv preprint arXiv:1907.11692, 2019.
- [21]Lewis Chinery and others. "Paragraph—antibody paratope prediction using graph neural networks with minimal feature vectors." Bioinformatics. 2023 Jan;39(1):btac732.
- [22]Krawczyk K, Baker T, Shi J, Deane CM. Antibody i-Patch prediction of the antibody binding site improves rigid local antibody-antigen docking. Protein Eng Des Sel. 2013 Oct;26(10):621-9. doi: 10.1093/protein/gzt043. Epub 2013 Sep 4. PMID: 24006373.
- [23] Xu X, Bonvin AMJJ. DeepRank-GNN-esm: a graph neural network for scoring protein-protein models using protein language model. Bioinform Adv. 2024 Jan 5;4(1):vbad191. doi: 10.1093/bioadv/vbad191. PMID: 38213822; PMCID: PMC10782804.

致谢

行文至此，已抵达最后部分。一路走来，百感交集。

本文能顺利完成，首先最要感谢的是我的导师王鑫老师。从论文选题，任务书，开题报告，中期检查，一路到初稿，二稿，终稿，在整个论文的过程，王鑫老师都尽职尽责，为我指点迷津，提供帮助。

感谢我的父母和我的哥哥，不论在处在何种境况下，家人们总是给我无限的支持，是我最坚强的后盾。

感谢我的舍友我的同学们，我们一起并肩走过最艰难的时刻，一起走过人生如此重要的阶段。

感谢深圳技术大学所有参与毕业生工作的老师和辅导员们，他们为我们答疑解惑，为全体毕业生的毕业工作尽心尽力。

感谢这一年的自己，路途虽然坎坎坷坷，但是总是想办法去前行，即便害怕也能生出勇气，即便辛苦也不曾放弃。

2024 下半年到 2025 上半年真是不平凡的一年。山重水复，大家陪着我跋山涉水，一直走到柳暗花明又一村的一刻。

再次表示诚挚感谢！